

# 低光影像增強之多模型整合實作與比較分析

學生姓名：宋佑杰

指導老師：林柏江 教授

## 摘要

在低照度環境中拍攝的影像常因亮度不足而出現細節流失、對比偏低與色彩失真等問題，進而影響後續辨識與分析效果。本研究針對低光影像增強任務，整合七種不同技術，包括三種傳統方法（LIME、Retinex、頻域濾波）與四種深度學習模型（RetinexNet、DRBN、Zero-DCE 與 EnlightenGAN），於統一資料集與實驗平台下進行全面比較分析。研究中導入後處理補光機制修正亮度不足現象，並透過客觀指標（PSNR、SSIM、BRISQUE、PI）與主觀觀察進行多維評估，驗證各方法在不同應用場景下之增強表現與限制，比較各方法的優缺點，並分析各模型具體適合應用在哪些領域。實作過程中發現多數原始開源模型存在訓練失效或結構缺陷，導致灰圖、過曝、色偏或模糊等問題，難以直接產出可比較之結果。因此，本研究針對每個失敗模型進行錯誤診斷與重構修正，包括重新設計 Generator 架構、補齊感知損失、調整亮度學習策略與正規化方法，透過整合與實作，本研究建構出涵蓋從無訓練到全監督的多樣增強技術架構，並針對其特性進行完整比較與分析，為未來低光影像處理任務提供選擇與分析依據。

## 1. 前言

隨著智慧攝影與電腦視覺技術日益應用於監控、醫療、行車輔助與工業檢測等場域，低光環境下的影像品質問題逐漸成為實務關鍵。由於自然或人為因素限制，許多攝影設備在低照度條件下拍攝的圖像，容易出現亮度不足、結構不明確與色彩失真的狀況，導致後續辨識與處理困難。因此，影像增強成為低光場景下的重要前處理技術。傳統方法如 Retinex 理論與頻域濾波運算雖能快速實現亮度提升，但在複雜場景中常因適應性不足造成過曝、色偏與邊緣損失。深度學習方法近年興起，透過大量數據學習低光與正常影像之間的對應關係，具備更高的還原能力與視覺品質。然而，這些方法在實際應用時亦面臨亮度失衡、細節缺失或訓練不穩定等問題。為此，本研究針對七種具代表性的低光影像增強方法進行整合與分析，建立統一訓練與評估平台，並設計後處理補光機制提升增強結果。研究除聚焦於模型性能比較，也記錄各模型的訓練挑戰與錯誤修正策略，從中歸納設計要點與改進方法。最終成果不僅有助於深入理解不同方法的適用場景與特性，也可作為後續學術研究與實務應用之參考基礎。

我在專題過程中從零建置完整實驗平台，實際訓練與推論七種模型，並針對出現失敗的模型（如灰圖、偏紅、模糊）進行完整修正與重構。並導入生成式 AI 輔助除錯與撰寫分析文段，大幅提升效率。透過這項經驗，我不僅深化了影像增強領域的技術理解，也學會如何將不同模型有系統地整合、比較與優化，並將技術成果轉化為可被閱讀與理解的學術報告。

## 2. 研究目標

- 評估不同方法於亮度、細節、自然度等面向之效能。
- 解決常見訓練錯誤，提供成功訓練參考架構與策略。
- 結合後處理補光機制，改善部分模型亮度不足的問題。

## 3. 模型技術說明

本專題共整合七個模型，分類如下。

表1. 模型分類

類型	模型名稱	是否需訓練	是否需配對資料
傳統方法 (無需訓練)	LIME, FreqFilter, RetinexTraditional	否	否
有監督深度模型	RetinexNet, DRBN, EnlightenGAN	是	是
無監督深度模型	Zero-DCE	是	否

### 3.1 傳統方法

基於數學理論（Retinex、頻域）、演算法固定、執行快速、運算資源需求低，適合在無需深度學習模型的情境下進行基準比較與實際應用。

LIME (Low-Light Image Enhancement via Illumination Map Estimation)

此方法以 Retinex 理論為基礎，假設影像為反射與光照的乘積，即  $I(x,y)=R(x,y)\times L(x,y)$ 。該方法認為亮度主要由光照控制，透過估計光照圖 (Illumination Map) 並將其除回原圖，即可完成亮度增強。

實作流程首先從每個像素的 RGB 三通道中選取最大值作為其光照代表值，藉此建構初始照明圖。該值被視為該像素受光照主導的亮度來源。為了使光照圖更平滑並避免突變與雜訊，進一步對其進行高斯濾波處理，以模擬真實場景中光照的自然漸變。完成照明圖平滑後，將原圖像除此光照圖達成「反向補光」的效果。最終結果需經裁切與正規化，將像素值限制於合法視覺範圍內  $[0, 1]$  或  $[0, 255]$ ，再轉為 PIL 圖像儲存為 .png 檔案。

此方法的主要優點是：可即時使用，不需 GPU 加速與模型訓練；在明顯暗部區域有明顯強化效果；增強邏輯簡單，解釋性強，特別適合學術教學與快速部署。然而，其缺點為：增強結果較粗糙，難以保留細節與紋理；在邊緣區域容易產生 halo 或過曝；此外，該方法無法依場景自我調整，對極低照度場景表現有限。

FreqFilter (頻域同態增強)

此方法來自於傳統影像處理理論「同態濾波」(Homomorphic Filtering)，其理論基礎同樣假設影像為光照與反射之乘積，即  $I=R\times L$ 。在對數空間下，該乘積可轉為加法形式  $\log(I)=\log(R)+\log(L)$ ，使光照與反射可分離，進而進行頻率濾波。

實作流程中，首先將影像轉為 YCbCr 色彩空間，並取出亮度通道 Y 作為主要增強對象。為了避免暗區在濾波後過於壓暗，先將亮度乘以 1.5 倍以進行預亮度補償。接著將 Y 通道轉為對數空間，並使用高斯型濾波函數：

$H(u,v)=1.5-0.5*\exp(-(D^2)/(2\sigma^2))$  來壓制低頻成分 (代表光照) 並放大高頻 (細節與邊緣)。濾波流程包含傅立葉轉換、頻域濾波處理，再反轉回空間域，完成後將增強後的亮度通道與原始色度資訊合併，重建彩色影像並轉回 RGB 格式輸出。

此方法的優點在於無需訓練，屬於純傳統圖像處理方法；運算成本低，適合 CPU 推論與嵌入式系統應用；並且可增強整體亮度與提升細節清晰度。然而，本方法亦存在若干缺點：若濾波器參數 (如  $\sigma$ ) 未適當調整，容易產生過曝與 halo 效果；原始處理結果偏暗，需透過亮度乘 1.5 及 `postprocess_gamma(gamma=0.5, gain=1.4)` 後處

理修正；此外，該方法不具備場景自適應能力，所有參數需事前手動設定。

RetinexTraditional (基於Multi-Scale Retinex, MSR)

此方法是根據 Retinex 理論實作的多尺度增強模型，模擬人眼對光照與反射分離的能力。該實作採用 PyTorch 框架，以卷積操作模擬高斯模糊，產生不同尺度的照明圖，再透過 log 差值實現傳統無需訓練的圖像增強。

本方法的基本假設是影像可分為反射成分 R (即物體本身資訊) 與照明成分 L (即光源影響)，即  $I=R\times L$ 。為了消除不均勻光照導致的暗部與色偏，並還原真實的色彩與細節，將輸入圖像 tensor 套用 `log()` 運算，轉為加法形式  $\log(I)=\log(R)+\log(L)$ ，使得後續可以透過差值運算消除照明項，保留反射結構。

在光照模擬方面，本方法使用 `single_scale_retinex()` 函數對每個 RGB 通道進行高斯模糊，並設定三種尺度  $\sigma$  值分別為 15、80、250，以模擬不同程度的光照變化。小  $\sigma$  值可去除小範圍陰影，大  $\sigma$  值則建模整體亮度。最後，將三個尺度的 Retinex 結果平均融合，提高穩定性與自然感，再透過 `tensor.min()` 和 `tensor.max()` 進行正規化，使輸出值域限制在  $[0, 1]$ ，避免過暗或過亮。

此方法的優勢為：無需模型訓練即可使用，運行快速，且強調邊緣與紋理的高頻細節；可手動調整模糊參數 ( $\sigma$ ) 以控制強度，具備高度可控性。不過，其缺點包括：原始輸出仍有偏暗現象 (已透過亮度乘 1.5 與 gamma 補償修正)；高頻過強易產生過銳與 halo 效果；且對於不同場景無法自我調整，屬於靜態非自適應方法。

表2. 傳統方法總結比較

模型名稱	增強方式	訓練	優點	缺點
LIME	光照圖 + 估計除法	否	快速有效、無需學習	色偏明顯、容易破壞結構
Retinex Traditional	多尺度 log 濾波	否	模擬人眼效果、穩定	偏色、過曝、不自適應

Freq Filter	對數 + 頻域濾波	否	細節保留佳、效果明顯	易 halo、需人工調參、偏暗
-------------	-----------	---	------------	-----------------

### 3.2 深度學習方法（有監督）

以下方法皆使用 paired 的 low/high 對應資料進行訓練，能透過結構分解、殘差學習與對抗訓練等技術，有效改善低光影像中的亮度不足、色彩偏差與細節模糊等問題。

RetinexNet (Retinex-based Decomposition and Enhancement Network)

此方法由 DecomNet 與 EnhanceNet 兩個子網路構成。DecomNet 採用 Encoder-Decoder 架構的 U-Net 設計，將輸入的低光影像分解為反射圖 R 及照明圖 I。Encoder 部分包含四層卷積與 ReLU 激活，每層後接 MaxPooling 用以提取特徵，Decoder 則透過三層上採樣接卷積，並與對應 Encoder 層進行跳接。最後網路分支為兩個輸出：R 經 sigmoid 激活為 3 通道 RGB 影像，I 則為經 sigmoid 限制的單通道照明圖。

EnhanceNet 用以進行照明補償與色彩校正。其 Encoder 為四層卷積，每兩層後進行一次二倍下採樣；中間瓶頸為兩層連續卷積以提取深層特徵；Decoder 則設計為三層上採樣，每層與對應 Encoder 層進行跳接並接續卷積。最終輸出為照明圖 I\_out (經 sigmoid 映射至  $[0, 1]$ ) 及色彩增強圖 Color\_map (經 tanh 映射至  $[-1, 1]$ )。整體增強結果計算公式為  $Enhanced = (R + Color\_map) \times I\_out$ ，並使用  $\text{clamp}(0, 1)$  確保像素值合法。訓練中，DecomNet 損失函數設計為重建誤差 (Reconstruction Loss) 以確保 R 與 I 能重建輸入影像，結構損失 (Structure Loss) 保持反射圖與原圖結構一致，及照明平滑損失 (Illumination Smoothness Loss) 促進 I 的平滑但不模糊邊

DRBN (Deep Recursive Band Network)

此方法設計核心為多層遞迴強化模組。整體架構由兩層 BandBlock 模組構成，每個 BandBlock 又包含多個 RecursiveBlock，負責進行深層特徵提取與非線性轉換。每個 RecursiveBlock 內部包含兩層卷積操作，搭配 ReLU 激活函數與 Batch Normalization，並加入殘差結構 (Residual Connection) 以提升訊息傳遞效率與梯度穩定性。

整體網路結構可描述為：初始圖像經 Head 卷積層處理後依序通過兩層 BandBlock，最終經 Tail 卷積層後以 tanh 激活，並使用  $\text{torch.clamp}$  將結果限制在  $[0, 1]$  範圍內。此架構強調多層級的

界。整體損失為  $\text{Reconstruction} + 0.1 \times \text{Structure} + 0.1 \times \text{Smoothness}$ 。

EnhanceNet 則進一步使用重建誤差 (Relight Loss) 與亮度正則項 (Brightness Regularization Loss) 使輸出亮度維持在  $0.4 \sim 0.7$  範圍內，搭配色彩一致性損失 (Color Loss)、結構損失 (Structure Loss) 及 Laplacian 邊緣強化損失，共同維持影像的色調與清晰度。總損失為  $1.0 \times \text{Relight} + 10.0 \times \text{Brightness} + 1.0 \times \text{Color} + 0.2 \times \text{Structure} + 0.1 \times \text{Laplacian}$ 。

訓練資料使用 LOL Dataset，為 paired 的 low/high 影像對，並採  $128 \times 128$  隨機 patch 作為訓練單位，加速收斂並增加數據多樣性。整體訓練分為兩階段，先訓練 DecomNet 一百輪，以確保 R/I 能穩定分解，再訓練 EnhanceNet 四百輪進行補光與增強。

推論時，將輸入影像透過已訓練完成的 DecomNet 與 EnhanceNet 處理，計算出增強影像為  $(R + \text{color\_map}) \times I\_out$ ，最後進行 clamp 操作，確保輸出合理。

此模型的優點在於：以 Retinex 理論為基礎，將低光影像拆解為反射與照明分別處理，可達分階段學習，提升穩定性與增強效果。架構不含判別器，訓練簡單、穩定收斂，適合部署在需要即時處理的場景。

然而，模型也存在若干缺點。首先，若 DecomNet 初期分解不準確（如 I 偏暗、R 偏灰），EnhanceNet 難以有效補救，分解階段錯誤會逐步累積放大。其次，照明圖 I 經過多次池化與上採樣後解析度下降，特別是在邊緣區域容易模糊。第三，EnhanceNet 僅以簡單的 color\_map 進行色彩修正，面對強烈色偏或白平衡異常情況時效果有限，缺乏專門的色彩變換模組。此外，模型未使用對抗學習，細節自然感稍弱，增強結果有時略顯平淡。過度平滑問題亦值得注意，Smoothness Loss 雖能促進亮度圖平滑，但同時可能抑制真實場景中應有的光照變化。最後，RetinexNet 僅能處理 paired 資料，無法直接應用於實際拍攝的 unpaired 場景，限制了其應用彈性。

結構資訊捕捉與增強，尤其在細節轉譯與質感還原方面具有明顯效果。

DRBN 損失函數設計方面，主要包含三個部分：一為 L1 損失，用以度量增強影像與目標影像之像素差距；二為 SSIM 損失，用以保留原圖結構與紋理特徵；三為色彩一致性損失 (Color Constancy Loss)，透過對 RGB 三通道的亮度均衡約束，避免增強過程產生偏色現象。總損失公式為： $\text{Loss} = \text{L1} + 0.3 \times \text{SSIM} + 0.05 \times \text{ColorConstancy}$ 。

設計理念上，此方法強調以 band 分解方式保留結構與原始資訊，後續再透過與 unpaired 視覺

偏好資料（如 Aesthetic Dataset）結合，提升輸出影像之視覺質感。儘管此架構原生設計支援感知損失與對抗訓練，本專題僅實作其 Step1 原始設定，即僅包含 RecursiveBlock 結構，並未引入 GAN 判別器，著重於結構與亮度層次的強化。

### EnlightenGAN（有監督改良版）

在本專題中採用其有監督改良版本，模型架構為一典型的生成對抗網路（GAN），由一個 ImprovedUNet 組成的 Generator 與一個 PatchGAN 結構的 Discriminator 組成。Generator 採對稱式 U-Net 設計，其 Encoder 包含四層卷積編碼器，將輸入影像解析度從 256 降至 16，Decoder 則為四層反卷積解碼器，恢復影像空間解析度，同時與 Encoder 層進行 skip connection。最終輸出經過 tanh 激活函數，再映射至  $[0, 1]$  範圍內，並使用 clamp 確保像素值落於合法區間。

該模型在訓練時採用 InstanceNorm 取代 BatchNorm，以提高小 batch 條件下的穩定性，Encoder 採 LeakyReLU 激活函數，Decoder 則使用 ReLU。此版本未引入殘差模組（Residual Block），保持結構簡潔。Discriminator 部分採用 PatchGAN 架構，並透過 Spectral Normalization 提升判別穩定性，其輸出為一張 16x16 尺寸的特徵圖，代表不同局部區域的真偽預測。

訓練資料方面，原 EnlightenGAN 為 unpaired 設計，本專題則改以 paired 模式訓練，使用 LOL Dataset 中成對的 low/high 影像對。圖像在輸入前統一 resize 至 256x256，並執行隨機水平翻轉進行資料增強，low 圖經過 gamma 還原處理（以  $\text{pow}(1/\text{gamma})$  方式實作，gamma 預設為 2.2），high 圖則直接轉為 Tensor 作為對應的 Ground Truth。

在損失函數設計上，EnlightenGAN 整合多種監督與感知損失以同時處理亮度不足、色彩偏差與結構模糊等問題。首先，生成器與判別器分別採用  $\text{g\_hinge\_loss}$  與  $\text{d\_hinge\_loss}$  作為對抗訓練的基礎；其次，模型採用 L1 損失以維持輸出與標準圖像的像素一致性；再者，加入 LPIPS 感知損失與 VGG perceptual loss，提升模型在語意層次上的還原能力。此外，也納入 SSIM 結構相似度損失、Color Loss（三通道亮度差異約束）、Laplacian Loss（強化邊緣銳利度），以及 TV Loss（Total Variation Loss）來促進空間平滑、抑制高頻雜訊。

為了提升穩定性與防止 artifacts，本研究於 Generator 輸出端添加 Sigmoid 激活並搭配 clamp 操作，同時透過 Self-regularization loss 限

制模型過度學習非實際特徵。Brightness loss 權重亦經調整，以控制生成亮度分布。

本專題所採用之 EnlightenGAN 改良版整合了亮度補償、色彩平衡與結構強化三大方向，並透過對抗式學習與多重感知損失達到整體影像品質最佳化。由於架構輕量，計算效率高，適合部署於即時影像處理應用。

然而該模型亦存在訓練風險，例如過度增亮或色彩偏移等問題，因此訓練中需嚴格監控亮度分布與損失趨勢。本專題中，透過 paired 設定與完整的損失組合，有效改善原始 unpaired EnlightenGAN 設計中模型不穩與難以收斂等缺陷，並最終取得具穩定性與自然感的增強成果。

### 3.3 深度學習方法（無監督）

無需 paired 的高光影像作為 Ground Truth，透過自設損失函數與統計特性約束，能讓模型從低光圖像中自動學習適當的增亮策略。

#### Zero-DCE（Zero-reference Deep Curve Estimation）

此方法強調模型不依賴任何高光標籤，而是從原始輸入中估計一組增亮曲線參數，達成圖像亮度與視覺感知的強化。

其核心在於學習一組針對輸入圖像動態生成的亮度曲線參數  $A$ ，該參數為每張圖量身定制，包含 8 組 RGB 增強係數，共計 24 個通道（ $8 \times 3$ ），代表每組增亮階段所需調整的色彩比例。這些參數會透過特定運算（`apply_curve` 函數）應用至原始輸入圖像，逐像素進行亮度調整。由於不需參照高光影像，Zero-DCE 屬於典型的 Zero-Reference 增強方法。

模型架構方面，Zero-DCE 前六層皆為卷積與 ReLU 激活組成的特徵抽取模組，通道數維持在 32；第七層則輸出 24 通道，對應上述的 8 組 RGB 曲線參數。輸出層使用 tanh 激活函數，將數值限制於  $[-1, 1]$  區間，以控制亮度調整的幅度不至於過強或過暗。不同於一般影像輸出型模型，Zero-DCE 的輸出為曲線係數，最終結果需經過參數應用與後處理步驟。

在損失設計上，Zero-DCE 透過四種損失函數共同引導模型學習穩定、自然的增亮結果。第一為 Color Constancy Loss，藉由約束 RGB 三通道的亮度差距，避免色偏現象產生；第二為 Spatial Consistency Loss（`SpaLoss`），透過灰階轉換與方向性差分運算（上下左右），確保增強後圖像在邊緣結構上與原圖保持一致性；第三為 Total Va

riation Loss，用以壓抑空間中的高頻雜訊與破碎紋理，提升影像平滑度，具有類似正則化作用；第四為 Exposure Loss，評估圖像的局部亮度是否接近理想值（預設為 0.6），模擬人眼對曝光程度的敏感性，促進模型學習出視覺可接受的亮度分布。

整體設計理念建立在「無監督條件下如何從數據本身獲得最佳亮度調整策略」。由於每張影像的亮度分布與內容差異甚大，Zero-DCE 採用 adaptive learning 的方式，每次訓練均針對當前輸入動態生成參數與目標，實現個別圖像的最佳增強。其訓練流程中並無固定 ground truth，而是以統計與感知為導向的損失函數進行反向學習，提供一種無需配對資料即可進行合理增亮的深度學習解決方案。

## 4. 訓練與推論流程

### 4.1 訓練平台與資料集

本研究所有深度學習模型皆採用 LOL Dataset 作為主要資料來源。該資料集為標準化的低光與高光影像配對資料，其中訓練集包含 low/high 對應影像各 485 張，驗證集則包含各 155 張。這些資料用於各模型之訓練與客觀品質評估（如 PSNR、SSIM 等指標）。

訓練平台方面，主要透過 Google Colab 進行開發與模型訓練，使用 PyTorch 作為實作框架。針對訓練難度較高之模型（如 RetinexNet、DRBN、EnlightenGAN），全程於 Colab 上完成訓練流程，並結合雲端硬體加速與儲存功能。為利模型復原與中斷續訓，每五輪訓練儲存一次 checkpoint，並於每二十輪（或五輪）輸出預覽圖像，觀察訓練進展與輸出品質。

### 4.2 推論策略

推論階段統一採用 RGB 三通道輸入，所有模型的輸出皆轉為影像檔（x.png）並同步生成經後處理版本（x\_post.png），用以模擬實際應用需求。部分模型（如 Zero-DCE、FreqFilter）之輸出結果偏暗，因此於推論階段加上後處理補償函數 `postprocess_gamma(gamma=0.5, gain=1.4)`，以改善亮度與視覺表現。此策略確保所有模型可在相似條件下進行比較，同時提升可視化展示效果。

### 4.3 訓練成效概述

各模型訓練過程皆紀錄其 Loss 值隨訓練輪數變化之趨勢，並根據輸出圖像的亮度、紋理與結構穩定性進行觀察與調整。以下整理三種主要深度學習模型之訓練重點與關鍵成效：

在 RetinexNet 訓練過程中，成功版本採用原始 GitHub 架構，並完整保留三項核心損失函數，包

括重建損失、照明平滑損失與反射圖結構一致性損失。為避免兩網互相干擾，訓練流程採交替策略，先訓練 DecomNet 分離出 R 與 I，再訓練 RelightNet 對 I 進行亮度增強。隨著 SSIM 與 Smooth 損失的加入，模型輸出從早期的灰圖逐漸改善為亮度正常之彩色圖像，Loss 從 1.8 快速收斂至 0.002。

DRBN 模型初期實作版本僅包含主幹結構，未納入 Band 模組與遞迴機制，導致輸出偏紅且模糊。最終成功版本完整還原 GitHub Step1 設計，包含雙層 BandBlock 與 RecursiveBlock 組成之遞迴網路，實現多尺度特徵融合與細節保留能力。模型結合 L1、SSIM 以及色彩一致性損失，最終訓練過程中 Loss 從 37 穩定下降至 9 以下，並產生具備自然紋理與準確色彩的增強圖。

在 EnlightenGAN 模型中，早期版本因缺乏 clamp 處理與 LPIPS 感知損失，導致輸出異常，常見灰圖與過曝現象。成功版本則引入 tanh 激活與 clamp 限制像素範圍於  $[0, 1]$ ，並補足 LPIPS 損失函數，同時建立自動預覽與圖像儲存機制以輔助監控訓練過程。預覽圖每 20 輪更新一次，觀察顯示亮度穩定提升，結構逐步清晰，最終能穩定生成自然彩圖。

整體而言，三個模型在完成調參與架構修正後皆達穩定訓練條件，其訓練流程與錯誤修正歷程亦納入後續分析章節中，以呈現模型強化過程與關鍵調整策略。

## 5. 客觀評估與主觀比較分析

本專題針對各模型之影像增強表現進行量化分析，統一以驗證集為基礎進行評估。選用的指標涵蓋 PSNR (Peak Signal-to-Noise Ratio)、SSIM (Structural Similarity Index)、BRISQUE (Blind/Referenceless Image Spatial Quality Evaluator) 與 PI (Perceptual Index) 四種，分別從像素還原、結構一致性、無參考畫質與感知品質四個層面，全面呈現模型的增強能力。首先在 PSNR 表現方面，EnlightenGAN 的評分最高，顯示其在重建圖像細節上最接近 Ground Truth，能有效復原像素資訊。RetinexNet 與 DRBN 的表現也相當穩定，數值略低於 EnlightenGAN，但仍展現良好還原能力。相較之下，傳統方法如 FreqFilter 與 LIME 的 PSNR 數值明顯偏低，顯示其在像素層次的增強表現存在較大誤差，無法精準還原原始場景。

在 SSIM 指標方面，DRBN 的結構保留能力最為顯著，其增強圖像保留了邊緣與紋理細節，整體結構相似度最高。RetinexNet 與 EnlightenGAN 雖略低於 DRBN，但表現仍然優秀，能兼顧亮度提升與結構一致性。傳統方法則在此指標表現不佳，尤

其 FreqFilter 與 LIME 在亮度提升過程中導致邊緣模糊與紋理流失，使結構還原效果明顯下降。

BRISQUE 作為無參考品質評估指標，模擬人眼觀感對圖像品質的直覺評價。結果顯示，Zero-DCE 與 DRBN 在此項表現最為突出，代表其增強圖像在自然感與視覺一致性上最接近人眼偏好。相對而言，RetinexNet 與 EnlightenGAN 雖然在 SSIM 上表現良好，但其 BRISQUE 分數偏高，顯示其增強結果中可能存在不自然的紋理或光照痕跡。LIME 在 BRISQUE 指標表現最差，原因可能為過強對比處理與區塊效應造成明顯人工感，導致整體畫質下降。

Perceptual Index (PI) 則進一步評估增強結果在人眼主觀感知上的整體滿意度。Zero-DCE 與 DRBN 再次取得最佳表現，顯示其圖像不僅結構合理，亦符合視覺審美。RetinexNet 與 EnlightenGAN 雖然在客觀還原指標表現優秀，但因存在色偏或過曝等問題，導致人眼感知上略顯不自然。LIME 再次於該指標失分，為整體感知品質最低者。

綜上所述，不同模型在各指標上展現出不同強項：EnlightenGAN 與 RetinexNet 擅長像素與結構還原；DRBN 則在結構穩定與視覺自然感方面兼具表現；Zero-DCE 於無參考與感知品質中取得優勢；而 LIME 與 FreqFilter 雖具備基本增亮能力，但在畫質與結構一致性上表現明顯不足。

表3. 客觀品質統計結果

模型	PSNR	SSIM	BRISQUE	PI	備註
FreqFilter	8.42	0.259	16.93	13.46	計算快、穩定性高、整體畫質中等
LIME	9.45	0.292	55.46	32.73	傳統方法代表、亮度強化顯著、結構與自然感雙失分
RetinexNet	17.60	0.717	36.32	23.16	還原與結構兼具、圖像略顯不自然（高 BRISQUE）
Retinex	13.82	0.584	17.26	13.63	計算快、穩定性高、整體畫質中等

Traditional					
ZeroDCE	12.08	0.458	4.04	7.02	自然感強（BRISQUE/PI 最佳）、輕量、還原精度（PSNR）中等偏低
EnlightenGAN	19.45	0.715	41.04	25.52	還原能力最強（PSNR）、人眼感受略差（PI 高）
DRBN	16.80	0.747	6.45	8.22	結構最佳（SSIM）、人眼感受佳（PI）、訓練時間長、需 paired data

（統一以 x.png（原始增強圖）為基準評估，避免後處理失真）




圖1. 平均指標統計圖

5.2 主觀觀察



其中FreqFilter，ZeroDCE因輸出圖不明顯，統一透過 gamma 與色彩補償等後處理修正偏暗與偏色問題，其他模型則用原輸出圖進行主觀觀察比對。

表4. 主觀視覺比對總結


模型	亮度表現	色彩表現	細節保留	整體觀感
----	------	------	------	------



FreqFilter	亮度不足，整體偏暗	偏冷綠色調	細節大量流失	太暗且無法辨識
RetinexNet	亮度正常，但易模糊	色彩偏淡，自然	細節模糊，無銳利邊界	畫質穩定但偏模糊
ZeroDCE	偏黃偏暗，提升有限	偏黃，色偏明顯	有邊緣資訊，但偏模糊	色偏明顯不自然
Retinex Traditional	亮度偏低，細節模糊	色彩較灰，欠自然	細節被平滑化	模糊且偏灰
LIME	亮度過高，偏綠偏黃	偏綠嚴重，失真	邊緣過度強化並伴隨雜訊	過曝且嚴重色偏
EnlightenGAN	亮度不足，泛灰	整體偏灰無彩度	細節模糊但乾淨	偏灰偏暗不真實
DRBN	亮度穩定，略偏暗	色彩自然但略失飽和	細節最佳，邊緣自然	整體最平衡，接近真實



RetinexTraditional



LIME




EnlightenGAN



DRBN



Low



GT



FreqFilter



RetinexNet



ZeroDCE



圖2. 視覺比對圖\_1



RetinexTraditional



LIME




EnlightenGAN



DRBN



Low



GT



FreqFilter



RetinexNet



ZeroDCE



圖3. 視覺比對圖\_2




圖4. 視覺比對圖\_3

## 6. 訓練失敗經驗與修正紀錄

### 6.1 失敗版本統整

#### EnlightenGAN

##### (1) 初期錯誤版本列表

- enlightengan\_old
- enlightengan\_old\_test
- EnlightenGAN\_TEST
- EnlightenGAN\_TEST2
- EnlightenGAN\_TEST3

- EnlightenGAN\_TEST4
- EnlightenGAN\_TEST5
- EnlightenGAN(正式版)

##### (2) 各版本詳細實驗記錄 + 小結

##### enlightengan\_old

- 失敗現象：
  - 增強效果極差，整張圖接近全黑或極暗，幾乎看不到內容。
  - 無論訓練多久，輸出結果均無實質提升。



圖5. enlightengan\_old

- 推測原因：
  - Generator 不是正確的 Unet 結構。
  - 缺少 skip connection，特徵無法有效傳遞。
  - 判別器和生成器損失設計極度不完整，只依靠 basic GAN loss。
- debug動作紀錄：
  - 檢查網路架構，發現Encoder-Decoder層數錯誤，跳接缺失。
  - 發現只有 adversarial loss，完全沒有 pixel loss 或 perceptual loss。
- 驗證結果：無法改善，全架構需重建。
- 小結：整體設計錯誤，必須全面重構Generator與Loss。

##### enlightengan\_old\_test

● 失敗現象：

- 圖像稍有亮度提升，但細節模糊嚴重，且整體仍暗。
- 有色塊與破碎現象。



圖6. enlightengan\_old\_test

● 推測原因：

- 嘗試補上部分 skip connection，但結構仍有問題。
- 損失函數依然不完整，主要問題是缺少感知損失與亮度學習。

● debug動作紀錄：

- 加入初步的 pixel loss。
- 但仍未補上 LPIPS 或 VGG perceptual loss。

● 驗證結果：亮度稍提升，但細節與整體質感失敗。

● 小結：結構小幅修正仍不足，缺少多層次損失監督。

EnlightenGAN\_TEST (早期修正版)

● 失敗現象：

- 增強結果稍微提升亮度，但偏灰且無對比。
- 色彩模糊且畫面整體偏暗。



圖7. EnlightenGAN\_TEST

● 推測原因：

- brightness\_loss 權重設太低。
- 輸出未進行 clamp 正則化處理。

● debug動作紀錄：

- 小幅提升 brightness\_loss 權重。
- 嘗試在輸出後 clamp (0,1)。

● 驗證結果：亮度略有提升，但灰度問題依然存在。

● 小結：亮度學習未充分推動，結構與損失仍需強化。

EnlightenGAN\_TEST2

● 失敗現象：整體畫面偏灰，亮度提升有限，暗部細節未恢復。



圖8. 原高光圖





圖9. EnlightenGAN\_TEST2

- 推測原因：
  - Generator架構修正不足，skip連線錯誤。
  - 損失設計仍偏單一，缺少高層次感知指導。
- debug動作紀錄：
  - 徹底修正 Unet 結構。
  - 開始加入 LPIPS 感知損失。
- 驗證結果：亮度略好，但畫面對比不足。
- 小結：架構改善有進步，但損失引導不夠全面。

#### EnlightenGAN\_TEST3

- 失敗現象：
  - 亮度偏灰，對比不足，畫面無層次感。




圖10. 原高光圖



圖11. EnlightenGAN\_TEST3

- 推測原因：
  - brightness\_loss 權重仍偏小。
  - 輸出值範圍未做充分控制。
- debug動作紀錄：
  - 將 brightness\_loss 權重提高至 50。
  - 輸出加入 clamp(0,1) 正則化。
- 驗證結果：整體亮度提升，但色彩層次感仍稍弱。
- 小結：亮度改善，但需要感知損失和結構損失同步提升。

#### EnlightenGAN\_TEST4

- 失敗現象：畫面出現明顯色塊，特別是暗部有破碎感。






圖12. 原高光圖



圖13. EnlightenGAN\_TEST4

- 推測原因：
  - adversarial loss 主導過強。
  - TV loss (空間平滑) 不足。
- debug動作紀錄：
  - 增加 TV loss 權重。
  - 使用 PatchGAN 判別器。
- 驗證結果：色塊減少，但暗區細節不均仍存在。
- 小結：對抗壓力控制後，畫面自然度有提升。

EnlightenGAN\_TEST5

- 失敗現象：
  - 畫面過曝，局部爆白，細節流失。




圖14. 原高光圖



圖15. EnlightenGAN\_TEST5

- 推測原因：
  - brightness\_loss 權重設太高 (150)。
  - perceptual損失權重不夠，無法維持細節。
- debug動作紀錄：
  - 將 brightness\_loss 調降至 50。
  - 加強 VGG perceptual loss 和 LPIPS感知損失。
- 驗證結果：爆白問題消失，細節恢復自然。
- 小結：控制亮度+強化感知損失後成功穩定亮度。

EnlightenGAN (正式版)

- 最終成功方案：
  - 正確復原 ImprovedUNet 架構 (含 skip connection)。
  - 使用完整損失組合：
    - d\_hinge\_loss / g\_hinge\_loss：用於防止判別器過度主導。
    - L1 loss：用於保持輸出圖像與目標圖像整體亮度與結構相似。
    - LPIPS：基於 VGG 特徵距離的感知損失，與人眼視覺一致性高度相關。
    - VGG perceptual loss：強化語意層次上的還原能力。

- SSIM loss：強調局部紋理與對比的保留，有助於提升細節真實感。
  - Color loss：RGB 三通道色彩一致性損失，透過最小化 (R-G)、(R-B)、(G-B) 差距來抑制偏色現象。
  - Laplacian loss：增強卷積核強調圖像邊緣變化與細節清晰度。
  - TV loss：用於強化空間平滑性，抑制高頻雜訊或區塊效應。
- clamp 輸出控制數值範圍。
  - brightness\_loss 使用  $F.relu(0.75 - brightness).mean()$  自然提升亮度。
  - 增強後可做 gamma補償（非統一後處理，而是模型專屬）。

● 結果：亮度均勻提升，色彩自然，細節清晰，無爆白或色塊。

表5. EnlightenGAN錯誤版本總結

版本	主要問題	debug動作	成果
enlightengan_old	全黑，結構錯誤	無 skip，錯誤設計	完全失敗
enlightengan_old_test	亮度提升但嚴重失真	部分修正 skip，損失仍缺	亮度提升但細節失敗
Enlightengan_TES	偏灰偏暗	小修 brightness_loss+clamp	亮度略提升但細節不足

Enlightengan_TES T2	偏灰，暗部無細節	改Unet結構+加LP IPS	對比改善但亮度不足
Enlightengan_TES T3	偏灰，色階不足	調整亮度損失+clamp輸出	亮度提升但層次偏少
Enlightengan_TES T4	色塊異常	加TV loss+控制adversarial壓力	色塊減少，自然過渡
Enlightengan_TES T5	爆白，細節消失	降低亮度損失+加感知損失	爆白修正，細節恢復
Enlightengan(正式版)	成功	完整結構+多損失+輸出正則化+亮度約束	亮度自然，細節清晰

## RetinexNet

### (1) 初期錯誤版本列表

- RetinexNet\_test1 ~ RetinexNet\_test18
- RetinexNet\_101-285
- RetinexNet(正式版)

### (2) 各錯誤版本詳細實驗記錄 + 小結

版本 A：灰圖問題（初始失敗）

- 結構問題：使用原始 RetinexNet 結構，未引入 BatchNorm 或深層殘差，模型太淺。
  - DecomNet 包含兩層 3x3 卷積（輸入 3 通道，輸出 64 通道），之後再以 3x3 卷積輸出 4

通道（前 3 通道為反射率  $R$ ，最後 1 通道為照明  $I$ ），並對  $R$  和  $I$  分別做 sigmoid 激活。

- RelightNet 則將  $R$ (3 通道)與  $I$  (1 通道)串聯後經過兩層 64 通道的  $3\times 3$  卷積，最後再以  $3\times 3$  卷積輸出單通道  $I'$  (增強後的照明)。

- 原因：DecomNet 缺乏聯合高光與低光雙向約束，無法學到  $R/I$  特徵，只有簡單的重建 Loss，導致模型容易收斂到非物理的理解 ( $R$  與  $I$  互補不佳)。Enhance 層直接生成平滑灰階圖。

- 對策：
  - 加入 BatchNorm。
  - clamp 限制輸出  $[0, 1]$ 。
  - 分階段訓練（先訓練 DecomNet 再訓練 EnhanceNet）。



圖16. 純灰圖

版本 B：亮度學習失敗

- 問題：亮度值接近 0.05，圖像幾乎全黑。
- 檢查：Enhanced 圖明顯低亮，brightness\_loss 長期為常數。
- 修正措施：
  - 將 brightness\_loss 計算從簡單 mean 改為  $F.softplus(0.7 - brightness)$ 。
  - 將權重調高至 10~50。



圖17. 純黑圖

版本 C：過度擬合高光圖

- 現象：增強後圖像異常完美，細節極度相似真實圖。
- 原因：模型偷吃 ground-truth，將反射圖當成目標直接模仿。
- 修正：
  - 將 loss\_color、loss\_R\_consistency 權重拉高，限制反射圖學習。
  - 降低 brightness loss 權重，防止單一項主導學習。



圖18. 原高光圖



圖19. 過度擬合高光圖

版本 D：雜訊擴大與光暈

- 現象：增強後圖像亮度提升，但暗部雜訊明顯被放大，由於加入了對高光圖像的訓練，模型可能較容易學到將低光直線亮化的策略，但細節和噪聲未被充分處理。實際結果可能出現過曝或強度不穩定（因高光圖訓練導致 R 值偏高）。
- 推測原因：反射層未正則化，照明圖過於突兀。
- 修正措施：
  - 為  $R_{pred}$  加入平滑與 L2 正則項。
  - 對照明圖  $I$  加入平滑損失項，並正規化至接近 1。



圖20. 原高光圖



圖21. 雜訊擴大與光暈

版本 E：色偏與模糊

- 現象：圖像略帶偏色，細節缺乏銳利度。
- 原因：Color loss 權重不足；感知與結構損失不足以還原細節。
- 優化策略：
  - 提高 perceptual loss 權重至 0.5~1.0。
  - 新增 SSIM loss 與 Laplacian loss 協助學習邊緣細節。
  - color loss 改為 histogram matching 或 HSV 空間對齊。



圖22. 原高光圖





圖23. 色偏與模糊

RetinexNet(正式版)

### 1. UNet 式 DecomNet 結構設計

- 目的：將原圖分解為反射分量 (R) 與照明圖 (I)。
- 改進內容：
  - 採用 Encoder-Decoder 架構並引入三層跳接 (Skip Connection)，強化淺層特徵與深層特徵融合。
  - 使用多層卷積與非線性激活 (ReLU) 提高表達能力。
  - 輸出層採 sigmoid，使 R/I 分布穩定於  $[0, 1]$  範圍。
- 優勢：
  - 能有效保留原圖的細節與結構資訊。
  - 跳接解決梯度消失問題，避免生成模糊照明圖或無效反射圖。

### 2. 深層 EnhanceNet 結構 (EnhanceNetDeep)

- 目的：根據 DecomNet 輸出的 R/I，重建照明圖與顏色映射，得到增強圖像。
- 改進內容：
  - 加深編碼層 (encoder) 至 4 層，強化模型捕捉全域光照與上下文關係的能力。
  - 中間層引入兩層卷積作為 Bottleneck。
  - 解碼層 (decoder) 採跳接結構，每一層都與對應編碼特徵融合。
  - 最終輸出兩個分支：

- 色增強圖 ( $I_{out}$ : 增強後的照明圖 (sigmoid 限定在  $[0, 1]$ )。
- color\_map: 顏 tanh 限定在  $[-1, 1]$ ，再映射至 RGB 範圍)。

### ● 優勢：

- 高層特徵融合提升圖像銳利度與對比度。
- 跳接減少細節流失與邊界模糊現象。
- 色彩與亮度分離處理，更精確控制輸出品質。

### 3. 多重損失

- Reconstruction Loss ( $L1$ )：對齊增強圖與 GT 像素差異，保證基本還原效果。
- Illumination Smoothness Loss：鼓勵照明圖在空間上平滑過渡，避免產生突變亮區與光暈。
- Structure Loss：強調反射圖應保有與原圖相似的邊緣與紋理結構 (以梯度差異衡量)。
- Color Constancy Loss：確保輸出圖與高光參考圖色彩趨近 (避免偏色)。
- Brightness Regularization Loss：約束平均亮度應落於  $[0.4, 0.7]$ ，避免全黑或過曝。
- Illumination Mean Loss：控制照明圖 I 的全域亮度平均值靠近目標值 (如 0.5)。
- Laplacian Loss：以拉普拉斯卷積計算邊緣強度，鼓勵輸出圖具有更強的輪廓與細節。

### 4. 優化策略與訓練流程

- 分階段訓練：先訓練 DecomNet (確保分解合理)，再加入 EnhanceNet 進行端到端微調。
- DecomNet 架構優化：由原始簡單卷積網路改為類 UNet 結構，引入多層下採樣與上採樣、跳躍連接 (Skip Connection)，強化圖像結構與語意特徵分離能力，改善 R/I 的可解性與穩定性。
- EnhanceNet 深度設計：從淺層單向結構進化為 Encoder-Decoder 風格深層網路，加入殘差模組 (ResBlock) 與跨層融合 (concatenation)，有效提升光照學習表現與細節還原能力。

- 輸出處理：使用 clamp 限制與 log 顯示 min/max，利於偵錯。
- 損失權重比例如下：

$$\begin{aligned} \text{總損失} = & 1.0 * L1 + 10.0 * \text{illumination\_smoothness} + 10.0 \\ & * \text{brightness\_reg} + 5.0 * \text{color\_constancy} + 0.5 * \text{perceptual} \end{aligned}$$

結果：最終模型結合了深層架構、跳接融合、照明控制、感知約束、色彩一致性、結構保留與亮度正規化，有效解決了先前所有版本中灰圖、雜訊、偏色、模糊與亮度失衡等問題，穩定產生自然、清晰且亮度適中的圖像輸出。

## DRBN

### (1) 初期錯誤版本列表

- DRBN\_test
- DRBN(正式版)

### (2) 各錯誤版本詳細實驗記錄 + 小結

#### DRBN\_test

- 失敗現象：
  - 初期訓練 loss 非常高（約 37.5），下降緩慢。
  - 增強結果偏紅、偏模糊，細節流失。  
預覽圖中可以看到床、枕頭等物體邊緣變得鬆散、不清楚，整體增強結果偏暗且色彩失真。



## 圖24. DRBN\_test

- 初步推測原因：
  - 模型架構過度簡化，遞迴模組堆疊層數太少。
  - 損失設計不完整，初版只使用單一 L1 Loss，缺少 LPIPS 感知損失、SSIM 結構損失。
  - 交叉融合層（Multi-Branch Fusion）未正確實作，導致多頻帶特徵傳遞失效。
  - 學習率設定過低，訓練初期模型收斂非常慢。
- debug動作紀錄：
  - 重建 DRBN 原始設計，包含遞迴模組堆疊 6 層，且每層有殘差結構。
  - 增加感知損失（LPIPS）以輔助高層次特徵學習。
  - 引入 SSIM 結構損失，保護局部結構穩定。
  - 檢查並修正 Multi-Branch 特徵融合方式，確保高、中、低頻資訊正確結合。
  - 調整學習率策略，起始 lr 提高至  $2e-4$ ，並設定 cosine annealing scheduler。
- 驗證結果：
  - 訓練 loss 從原本 37 快速下降到 6~7 範圍內。
  - 預覽圖中增強結果色彩自然、細節清晰，偏紅現象消失。
  - 紋理細節、邊緣線條清楚可見。
- 實驗小結：
  - DRBN 的成功關鍵在於：
    - 保留完整的遞迴堆疊結構
    - 使用多重損失 (pixel loss + perceptual loss + SSIM loss)
    - 確保特徵融合正確 (multi-band融合)
  - 單一 L1 loss 過於簡單，無法支撐複雜特徵學習，必須結合感知與結構指標進行監督

#### DRBN(正式版)

- 最終成功方案：
  - 遵循原始論文設計，完整堆疊 6 層 Recursive Band Module。
  - 損失組合：
    - L1 損失：對應原圖與輸出圖的 pixel 損失。

- SSIM Loss: 評估結構保留 (多尺度結構相似度)。
- Color Loss: 維持 RGB 三通道亮度一致, 避免偏色
- 正確實作多頻帶特徵融合 (multi-branch feature fusion)。
- 使用 CosineAnnealingLR 調整學習率, 穩定收斂。

表6. DRBN錯誤版本總結

版本編號	主要問題	Debug動作	成果
test	高loss、模糊、偏紅	重建完整遞迴結構 + 加 LPIPS/SSIM loss + 修正 multi-branch融合	成功恢復細節與色彩
正式版	成功	完整網路結構 + 多重損失監督 + 正確特徵融合	細節清晰, 色彩自然

## Zero-DCE

### Zero-DCE 初版

- 失敗現象：
  - 增強結果色偏 (偏黃/偏綠), 且部分區域過曝 (局部白爆), 其他區域仍然太暗。
  - 整體視覺品質不均勻, 畫面亮暗區域過渡不自然。
- 初步推測原因：
  - 增強曲線學習不穩定, 曝光控制不充分。
  - 損失函數設計中, 色彩恆常性損失 (color constancy loss) 與曝光控制損失 (exposure control loss) 權重設置不當。
  - 訓練過程中可能未強化正則化條件, 導致增強曲線產生極端變形。
- debug動作紀錄：

- 增強 Color Constancy Loss 權重, 從 1 → 10, 強化三色通道平衡。
- 調整 Exposure Control Loss 權重, 強化暗部區域的亮度提升但防止爆光。
- 訓練過程中加入曲線正則化約束 (Smoothness Loss) 以抑制曲線劇烈變化。
- 重新初始化曲線參數, 使初始曲線更接近 Identity (避免一開始過度增強)。

### ● 驗證結果：

- 色偏問題明顯改善, 三通道色彩接近正常比例。
- 暗部提亮效果更自然, 局部爆白區域顯著減少。
- 整體亮度均勻提升, 細節保留較好。

### ● 實驗小結：

- Zero-DCE 成功關鍵是「三重約束」：
  - 色彩恆常性 (防止偏色)
  - 曝光控制 (防止局部爆光)
  - 曲線平滑化 (防止學到極端操作)
- 單純依賴像素損失不足, 必須額外約束曲線學習行為, 才能產生穩定自然的增強效果。

### Zero-DCE(正式版)

### ● 最終成功方案：

- 加強 Color Constancy Loss 和 Exposure Control Loss 的監督力度。
- 在訓練時加入 Smoothness Loss 約束曲線平滑。
- 調整曲線初始化為接近 Identity Mapping。
- 使用更合理的 learning rate schedule (cosine annealing)。

最終結果：色彩自然, 亮度提升均勻, 暗區細節明顯可辨, 無過曝問題。

## FreqFilter

### FreqFilter 初版

### ● 失敗現象：

- 增強後圖像整體偏暗，且細節不明顯。
- 即使經過頻域處理，高頻細節區域仍然灰暗、對比不足。
- 預覽圖中，明暗對比不夠強烈，整體畫面偏平淡無力。
- 初步推測原因：
  - 同態濾波中，低頻放大比例設定過低，高頻增強比例設定不合理。
  - 濾波器參數 ( $\gamma_H$ 、 $\gamma_L$ 、 $D_0$ ) 選得不當，導致低頻與高頻分離不良。
  - 頻域增強後未進行 gamma 校正或其他非線性補償，導致人眼視覺感覺仍偏暗。
  - 直流分量 (DC分量) 補償不足，影像整體亮度被拉低。
- debug動作紀錄：
  - 調整  $\gamma_H$  (高頻增強倍率) 至 2.0、 $\gamma_L$  (低頻壓抑倍率) 至 0.5，使高頻特徵增強更明顯。
  - 微調  $D_0$  (截止頻率) 以控制增強區域範圍。
  - 在增強完成後，加入 gamma 補償 ( $\text{pow}(1/1.4)$ ) 以提高人眼視覺亮度。
  - 同時增加 DC分量回復 (防止黑化)，確保基礎亮度不被過度壓制。
- 驗證結果：
  - 增強後畫面明暗對比明顯提高，細節清晰。
  - 整體亮度提升，畫面不再灰暗。
  - 高頻紋理清楚，例如牆面紋理、物體邊緣變得清楚可辨。
- 實驗小結：
  - FreqFilter 成功關鍵是「雙重調控」：
    - 調整頻域濾波器參數，讓低頻與高頻分離效果最佳化。
    - 在空間域補上適當 gamma 補償與 DC 分量復原，使整體畫面視覺更自然。
  - 同態濾波後直接輸出會偏暗，必須經過感知校正才符合人眼需求。

FreqFilter(完整版)

- 最終成功方案：
  - 濾波參數調整：

- $\gamma_H = 2.0$  (高頻增強)
- $\gamma_L = 0.5$  (低頻壓制)
- $D_0 = 30$  (頻率截止)
- 增強後加 gamma 補償 ( $\text{pow}(1/1.4)$ )，提升整體視覺亮度。
- 保留直流分量，確保基礎亮度水平。

最終結果：細節明顯提升，畫面亮度自然，紋理清晰，增強效果符合人眼感知。

## Retinex Traditional

Retinex Traditional 初版 (單尺度 SSR)

- 失敗現象：
  - 增強後影像整體偏灰白，顏色飽和度極低。
  - 明暗細節雖有提升，但色彩感覺漂白、失去真實感。
  - 圖像中各個物體的色調差異變小，像是套上了一層灰霧。
- 初步推測原因：
  - 使用單尺度 Retinex (SSR, Single Scale Retinex) 時，對不同尺度的光照變化處理不足。
  - 缺少 Color Restoration 函數 (色彩恢復補償)，無法修正 log域計算帶來的色偏問題。
  - 未考慮不同頻率成分的光照與反射分離，導致結果偏灰。
- debug動作紀錄：
  - 改為使用 Multi-Scale Retinex (MSR)，結合多個不同模糊尺度的處理結果，涵蓋不同空間頻率。
  - 加入 Color Restoration Function (CRF)：
    - 用以恢復色彩比例關係。
  - 進行 gamma 補償 ( $\text{pow}(1/1.4)$ ) 微調人眼感知亮度。
  - 對結果加上亮度裁剪 (clamp) 防止過曝或過暗。
- 驗證結果：
  - 色彩飽和度明顯回升，畫面更加自然。
  - 明暗細節提亮，但不會造成整體漂白。
  - 物體本身色調差異保留，畫面更符合自然感覺。
- 實驗小結：
  - 傳統 Retinex 成功關鍵是：



- 同時考慮多尺度光照變化（多尺度平滑）
- 加入色彩恢復校正（CRF）
- 針對人眼感知進行適度 gamma 補償
- 單純使用單尺度 SSR 容易造成「色彩失真+過度提亮」問題，必須結合 MSR+CRF 才能取得自然增強效果。

#### Retinex Traditional(正式版)

- 最終成功方案：
  - Multi-Scale Retinex（多尺度模糊核分別處理並加權平均）。
  - 引入 Color Restoration Function（CRF）補償。
  - 增強後 gamma 微調（ $1/1.4$ 次方），符合視覺感知。
  - 輸出加 clamp 保護亮度範圍。

最終結果：色彩自然，亮度均勻提升，畫面真實感保留，無灰霧現象。

#### LIME

##### LIME 初版

- 失敗現象：
  - 增強後畫面出現局部過亮（halo effect），部分暗區仍偏黑。
  - 整體亮度分布不均勻，有明顯的光暈與斑塊感。
  - 暗區的噪聲因增強被放大，畫面出現雜點。
- 初步推測原因：
  - 照明圖估計（illumination map estimation）不足，細節過度跟隨原圖紋理。
  - 照明圖優化（smoothness refinement）過弱，未能抑制局部極端光照。
  - 暗部噪聲未經處理，直接增強後噪聲一併放大。
- debug動作紀錄：
  - 增強照明圖優化處理，使用結構引導平滑（structure-aware smoothing），防止細節導致照明分布不均。

- 在亮度增強後，針對暗部採取弱增益策略，避免暗部噪聲被無限放大。
- 加入後處理步驟（可選）：低通濾波器去除暗部噪聲。
- 將強化後影像進行 gamma 補償（ $\text{pow}(1/1.4)$ ）提升整體視覺自然度。

##### ● 驗證結果：

- 光暈現象顯著減輕，畫面亮度過渡更平滑。
- 暗區噪聲大幅降低，整體畫面更乾淨。
- 增強效果穩定，亮暗區域分布自然。

##### ● 實驗小結：

- LIME 成功關鍵是：
  - 加強照明圖平滑處理（避免局部極亮）
  - 暗區噪聲適當控制（避免噪點被放大）
  - 後處理 gamma 補償符合人眼感知
- 單靠基本照明估計容易導致局部過曝與噪聲問題，必須結合空間平滑與增強範圍控制。

#### LIME(正式版)

- 最終成功方案：
  - 使用 structure-aware smoothness 強化照明圖平滑。
  - 暗區增益抑制（限制最大增亮倍數）。
  - 後處理 gamma 補償改善亮度感知。
  - 輸出 clamp 保護最終範圍。

最終結果：亮度自然分佈、無過曝、無光暈、噪聲降低。

## 6.2 模型結構與訓練機制優化分析

本專題多次驗證顯示，深度學習架構中的模型結構設計與訓練機制設計，對影像增強品質有著關鍵性影響。在模型架構設計部分，若未能建立具備有效特徵傳遞或強化能力的深層結構，往往會導致模型無法提取足夠資訊，產生增強失敗的結果。

例如 EnlightenGAN 初期版本中未正確實作完整的 U-Net 型 Generator，造成低階特徵難以傳遞至解碼器階段，導致增強圖像偏灰且亮度不足。RetinexNet 初始版本亦因 DecomNet 結構過於簡

化，導致模型無法有效區分反射與照明成分，亮度提取失效。DRBN 的早期版本缺乏足夠的遞迴層數與多分支融合設計，特徵表徵能力有限，使輸出影像模糊且色彩失真。上述經驗總結可得，唯有建構具有跳接連結（如 U-Net）或遞迴強化模組（如 recursive band block）的深層結構，才能保留完整空間資訊，實現有效的影像增強。在損失函數設計方面，本研究進一步證明單一損失難以涵蓋所有增強目標，唯有結合多種損失函數並調整其權重，才能同時兼顧亮度、對比、細節與色彩等多維表現。EnlightenGAN 的成功訓練案例中，結合 pixel loss、LPIPS 感知損失、VG G perceptual loss、TV loss 與 brightness loss，有效協助模型在提升亮度同時保留細節與視覺一致性。RetinexNet 經由結合 illumination smoothness loss、structure loss 與 color loss，不僅穩定了照明估計，亦有效解決灰階問題。Zero-DCE 則在加入 exposure control loss 與 color constancy loss 後，於曝光均勻性與色彩協調上表現顯著提升。此外，訓練流程與資料處理策略亦為模型成敗之重要關鍵。在 RetinexNet 與 EnlightenGAN 的訓練經驗中，採用交替訓練（alternate training）方式可使多分支子網同步學習、彼此協調，避免訓練失衡。其中，RetinexNet 成功案例中 DecomNet 與 EnhanceNet 分階段進行訓練，可有效對應亮度分離與補償的需求。EnlightenGAN 則在每輪訓練中配合圖像預覽與平均亮度監控機制，能即時追蹤模型輸出趨勢，並動態調整損失項之權重，以防止過曝或偏暗現象。訓練過程中，合理的資料擴增手段（如隨機水平翻轉、裁切）與 gamma 補償亦有助於提升模型泛化能力與輸出影像的自然感。綜合來看，一個穩定的訓練流程應具備以下三項條件：第一，多分支子網需同步協調訓練；第二，訓練過程中應定期預覽並分析輸出特徵；第三，應根據統計特徵動態調整損失與亮度控制策略。唯有如此，方能有效避免模型陷入局部最小值，並穩定收斂至高品質的影像增強解。

### 6.3 總結

在本專題初期階段，由於對低光影像增強的深度學習技術尚不熟悉，對於模型結構與損失設計的理解亦不夠全面，導致多次訓練過程出現輸出全黑圖、灰圖、過曝或偏色等問題。以 EnlightenGAN 與 RetinexNet 為例，若模型結構設計或同步訓練機制設定錯誤，將直接影響模型學習能力，使其無法提取有效特徵，進而失去增強能力。過程中需不斷回溯調整、debug 與重構，才能逐步穩定訓練。

此外，資料處理的正確性亦為關鍵因素。初期實作曾因 low/high 圖像配對錯誤或數據

正規化操作失當，導致模型損失無法收斂，需經過多次錯誤定位與修正後才獲得穩定學習結果。從這些實務經驗中歸納出以下反思：首先，模型結構設計應明確對應任務需求，不可沿用他法模板；其次，針對不同增強目標需設計具針對性的損失組合與合理權重；第三，訓練流程需隨時監控關鍵指標（如亮度分佈、LPIPS 感知分數）以動態調整策略；第四，需具備系統性 debug 能力，能從資料前處理、網路結構、損失設計與優化器設定等多個層面有系統地逐一排查。未來若能進一步深入本領域研究，考慮以下三點為進一步優化方向：其一，引入 Transformer 架構進行特徵抽取，強化對細粒度資訊的捕捉能力；其二，設計具備自適應權重調節能力的損失組合機制，使模型能自我平衡不同目標之學習強度；其三，結合對比學習（Contrastive Learning）技術，提升低亮與高亮區域之整體一致性表現；其四，優化資料增強與合成技術，模擬更多實際場景之低光變化，進一步強化模型的泛化能力。

## 7. AI協作部分

本專題期間，為了提高技術開發的效率與解決遇到的技術挑戰，我適度運用了生成式AI作為輔助工具。

AI主要在資料查詢、技術確認、錯誤排除建議等方面提供輔助，協助我更快掌握知識脈絡並完成技術驗證。以下具體說明協作過程。

### 1. 技術方向與基礎確認

在專題初期釐清低光影像增強領域的主要技術時，我以生成式AI作為快速查詢來源之一，用來了解如 RetinexNet、EnlightenGAN、Zero-DCE 等方法的基本原理和結構特點。這些初步資訊幫助我更有效率地進行文獻閱讀與技術選擇，但專題方法的最終確認仍依據我自己對論文內容和開源代碼的分析判斷。

### 2. 模型訓練過程中的錯誤排查

在模型訓練階段，遇到如輸出灰圖、亮度異常、收斂失敗等問題時，我會整理目前的訓練現象、損失曲線變化等資料，詢問AI提供可能的問題原因或修正方向。AI提出的可能建議（如補充感知損失、調整亮度正則化、修正結構跳接）成為我實驗設計的參考之一，但具體的測試、修改與最終修正結果，還是得由我自己動手實施與反覆確認。

舉例來說，在 EnlightenGAN 訓練出現灰圖時，AI提醒我可能與 Unet 結構的 skip connection 斷開有關，我實際上去比對原始架構並手動重建跳接，重新訓練後才成功修正。在 RetinexNet 訓練出現亮度不足時，我根據AI的建議補上 mutual consistency 與 illumination smoothness 損失，並通過交替訓練逐步穩定結果，遇到曝光或模型學習不佳的情況則需要手動不斷調參數重新訓練比對。

### 3. 推論與後處理調整

在推論階段，為了使不同模型輸出的結果更加一致，我參考了AI建議的 gamma 補償與增益調整策略，

並親自測試各種後處理參數組合，決定了適合大部分模型的統一後處理流程，同時為 EnlightenGAN 特別保留了其原有的 gamma 還原方式。

### 4. 報告撰寫與技術整理

在報告撰寫階段，尤其是在整理失敗案例與優化過程時，我曾向AI諮詢過段落結構與技術敘述的表達方式。這有助於我讓技術內容更有條理地呈現，但所有具體的實驗細節、錯誤修正經過、結果分析，仍是根據我自己的真實實驗紀錄撰寫完成。

### 5. 小結

生成式AI在本專題中提供了有效的技術輔助，包括快速查詢、錯誤排查提示與語言組織建議。但整個專題的系統設計、模型建構、訓練調整、錯誤修正、推論整合與最終成果產出，仍需靠自己主導完成，並且AI常會出現騙人的情況，也就是你問他錯了有什麼改進方式他會故意給你完全不可行的方式，有時甚至訓練過程已經出現問題他還會和你說一切正常，所以在比較大的專案中如果全信AI的話常會出現很多問題從而浪費許多時間及精力，也因此本身也要具備一定的 debug 能力。

雖然如此，只要不全靠AI，而是將其視為輔助工具，在適當時機利用，就能極大的提升專題開發的效率，而這次的專題經驗也加強了我在影像增強與深度學習領域的實作經驗與獨立解決問題的能力。

## 8. 結論

表7. 各模型比較

模型	適用場景	選用理由	優點	風險與限制
----	------	------	----	-------

DRBN	智慧監控、夜間攝影、影像辨識前處理	整體表現平衡，結構保留佳，視覺自然	PSNR/SSIM 高、畫面自然、LIPIS感知強、訓練穩定	訓練需 paired 資料、訓練耗時
RetinexNet	工業檢測、自駕車感知、醫療影像	分解+增強雙模組設計、適合處理結構敏感型影像	架構輕量、推論快、物理理論支撐、訓練穩定	I 分解品質直接影響結果、亮度補償不如 GAN 類強
EnlightenGAN	手機相機、即時夜拍、夜間補光系統	本專題改良版為有監督 GAN，亮度強化最佳	高亮度輸出、亮區穩定、感知損失多樣、訓練可控	色偏仍略重、對極暗區域容易偏綠偏紅
Zero-DCE	設備資源有限、無 ground truth 場域	不需 paired data、訓練簡單、可快速部署	快速訓練、推論快、部署靈活	容易過曝、畫面偏黃偏色、亮度不穩
FreqFilter	邊緣裝置、嵌入式系統、工業感測	不需訓練，可 CPU 執行、細節增強顯著	無需 GPU、細節清楚、無需學習	較暗、不可 adapt、需後處理補光
Retinex Traditional	學術對照、工程分析、固定場景應用	傳統 Retinex 多尺度設計，參數可控	模擬人眼效應、穩定性佳	無 adaptiveness、略顯平淡、需手動調整參數

LIME	教學用、光照圖估計示意	經典照明圖估算法、適合展示 Retinex 理論	可解釋性強、簡單易懂	噪聲大、色偏重、破壞結構明顯
------	-------------	--------------------------	------------	----------------

8.1 各模型比較結論

綜合本研究所整合與實作的多種低光影像增強模型，從結構設計、增強效果、客觀指標與主觀感受進行全面評估後，可歸納以下幾項主要成果：

首先，在整體平衡表現方面，DRBN 為本次專題中整體表現最佳的模型。其 SSIM 達 0.747，顯示其對圖像結構的保留能力優異，並且在無參考畫質評估 BRISQUE 指標上亦有亮眼表現（僅 6.45）。主觀觀察亦可發現其增強影像亮度自然、無明顯偏色，整體貼近真實場景，極具實用潛力，尤其適用於智慧監控、醫療影像預處理等實務應用場景。

若考量物理一致性與細節準確度，RetinexNet 則為邏輯推理表現最佳者。其 PSNR 為 17.6，SSIM 為 0.717，皆顯示其對原始結構有良好還原能力。該模型以 Retinex 理論為基礎，能有效分離紋理與光照，並於本專題中成功修復原本的偏灰問題，適合需可解釋性與穩定輸出的應用場域。

在亮度補償方面，EnlightenGAN 具備最強的提升能力，其 PSNR 高達 19.45，明顯高於其他模型，顯示其在極暗條件下能大幅提升圖像亮度。然而，其 BRISQUE 值達 41.04，反映出細節恢復上仍存失真問題。綜合來看，EnlightenGAN 適用於極低照度的場景，如手機夜拍、即時監控等，但仍需進一步優化視覺自然度。

Zero-DCE 則因其無需 Ground Truth 並能透過自設損失進行靈活訓練，在模型部署與快速應用上具明顯優勢。其在 PI (Perceptual Index) 上表現最佳 (7.02)，但主觀畫面偏黃且部分場景存在明顯失真，故較適合於邊緣裝置或資料資源受限的場景，如 IoT 裝置或即時視訊傳輸應用中。

在傳統方法部分，FreqFilter 雖能保留一定程度的細節，但整體亮度提升有限，PSNR 最低；RetinexTraditional 表現相對穩定，但易產生色偏；LIME 雖有較強提亮效果，但也伴隨明顯的失真與偏色情況，整體品質不佳，實務應用價值有限。

8.2 總結及未來展望

本專題系統性地整合並比較了七種低光影像增強方法，涵蓋傳統處理與深度學習範式。在統一平台上對比分析後，提出了多項觀察。研究發現：深度學習模型（特別是 EnlightenGAN 和 DRBN）在細節還原和結構一致性上優於傳統方法；Zero-DCE 則在感知自然度上更勝一籌；傳統方法固然

運行快速、基礎穩定，但難以滿足極低光照場景下的增強需求。通過案例分析，凸顯了架構設計與多重損失的重要性，並提出後處理補光策略以彌補亮度不足。此外，個人在專題中結合生成式 AI 工具快速查詢技術資料、進行訓練排錯，這些經驗證明合理使用輔助 AI 能提高開發效率，但核心方法依然來源於對論文與代碼的深入理解。

本專題對低光影像增強領域有以下價值與意義：

(1) 透過統一的實驗架構與訓練設定實作訓練主流低光影像增強模型

(2) 彙整了訓練與優化經驗，對後續開發具指導意義

(3) 針對訓練效果不佳在或結構缺陷的原始開源模型進行重構修正

(4) 通過客觀與主觀評估展示了各方法的優劣勢，提供了實驗參考數據，並分析各種模型的實際適用情景

在未來發展上，則可從以下幾個方向進行強化與延伸：首先，擴充訓練資料來源，尤其針對合成低光場景與真實夜拍影像進行建構；其次，導入跨域風格轉換技術如 CycleGAN，以增強模型適應性；第三，嘗試融合多模組架構，例如結合 Retinex 理論與 GAN 框架，以取得更佳的亮度與細節表現；第四，研發自動化後處理參數選擇機制與畫質評估工具，提升模型穩定性與應用效率；此外，亦可整合更多亮度與色彩校正後處理策略，並納入更多主流模型進行比較，並在訓練機制方面持續探索優化策略，以進一步提升模型學習效率與增強品質。

資料來源

- Wei, C., Wang, W., Yang, W., & Liu, J. (2018). *Deep Retinex Decomposition for Low-Light Enhancement*. In *Proceedings of the British Machine Vision Conference (BMVC)*.
- Li, C., Gu, S., Liu, J., & Loy, C. (2020). *Zero-Reference Deep Curve Estimation for Low-Light Image Enhancement*. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*.
- Jiang, Y., Gong, X., Liu, D., Cheng, Y., Fang, C., Shen, X., & Yang, J. (2021). *EnlightenGAN: Deep Light Enhancement Without Paired Supervision*. *IEEE Transactions on Image Processing*, 30, 2340 – 2349.
- Yang, W., Wang, S., Fang, Y., Wang, Y., & Liu, J. (2020). *From fidelity to perceptual quality: A semi-supervised approach for low-light image enhancement*. In *Proceedings of the IEEE*



E/CVF Conference on Computer Vision and Pattern Recognition (CVPR) (pp. 3063 – 3072).

5. Guo, X., Li, Y., & Ling, H. (2017). *LIME: Low-Light Image Enhancement via Illumination Map Estimation*. *IEEE Transactions on Image Processing*, 26 (2), 982 – 993.
6. Land, E. H., & McCann, J. J. (1971). Lightness and Retinex theory. *Journal of the Optical Society of America*, 61(1), 1 – 11.
7. Oppenheim, A. V., Schaffer, R. W., & Stockham, T. G. (1968). *Nonlinear Filtering of Multiplied and Convolved Signals*. *Proceedings of the IEEE*, 56 (8), 1264 – 1291.